Analyse de performance et optimisation de code

AYOUB Pierre – BONNAFOUS Camille – FLAMANT Océane

3 avril 2019

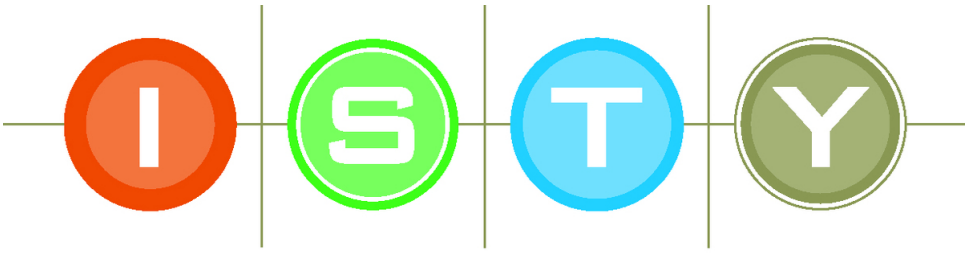

INSTITUT DES SCIENCES ET TECHNIQUES DES YVELINES

Résumé

La simulation numérique est un procédé informatique visant à modéliser un phénomène par ordinateur, s'agissant le plus souvent d'un phénomène physique. Cette modélisation prend forme par des systèmes d'équations décrivant l'état du système physique représenté à chaque instant. De nombreux domaines scientifiques convergent vers la simulation informatique, tel que certaines branches de la physique, de l'analyse et de l'optimisation mathématique, ou encore le calcul haute performance en informatique. Enfin, la simulation trouve naturellement de nombreuses applications concernant des sujets variés, tel que la simulation du climat et des évènements météorologiques, la simulation d'essais nucléaires, de l'effet d'un médicament sur un corps, ou encore des astres et de l'univers. Ce rapport s'articulera donc autour de l'analyse et de l'optimisation d'un code de calcul, cœur des simulations numériques présentés ci-dessus.

Table des matières

1 Introduction

Le projet que nous vous présentons aujourd'hui consiste à analyser puis, grâce à nos mesures, optimiser un code de calcul, appelé kernel. Les mesures doivent s'effectuer à l'aide de l'instruction *x86 RDTSC*, et des deux outils d'analyse de performance suivant : *MAQAO* et *LIKWID*. *RDTSC* nous permet de mesurer le nombre de cycles entre deux instants, *MAQAO* rends possible l'exécution d'analyses statiques (*CQA*) et dynamiques (*LPROF*) d'un binaire, présentées par un rapport haut niveau à l'aide de *ONE-VIEW*, enfin *LIKWID* permet d'obtenir un grand nombre de métriques très précises concernant, notamment, l'usage de la mémoire.

Afin d'étudier les différents niveaux de la hiérarchie mémoire, chaque membre du groupe analysera un niveau qu'il se verra assigné. Ci-dessous la liste des assignations :

Pierre Cache L1 :

- Intel Core i7-6600U @ 2.8 GHz, Skylake 6$^{\text{ème}}$ génération, 14nm, 2 cœurs 4 threads (Hyper-Threading)
- 32 KiB L1i, 32 KiB L1d (par coeur)
- 256 KiB L2 (par coeur)
- 4096 KiB L3 (partagé)

Océane Cache L2 :

```
--------------------------------------------------------------------------------
CPU name:       Intel(R) Core(TM) i7-5500U CPU @ 2.40GHz
CPU type:       Intel Core Broadwell processor
CPU stepping:   4
********************************************************************************
Hardware Thread Topology
********************************************************************************
Sockets:                1
Cores per socket:       2
Threads per core:       2
--------------------------------------------------------------------------------
HWThread        Thread          Core            Socket          Available
0               0               0               0               *
1               0               1               0               *
2               1               0               0               *
3               1               1               0               *
--------------------------------------------------------------------------------
Socket 0:               ( 0 2 1 3 )
--------------------------------------------------------------------------------
********************************************************************************
Cache Topology
********************************************************************************
Level:                  1
Size:                   32 kB
Cache groups:           ( 0 2 ) ( 1 3 )
--------------------------------------------------------------------------------
Level:                  2
Size:                   256 kB
Cache groups:           ( 0 2 ) ( 1 3 )
--------------------------------------------------------------------------------
Level:                  3
Size:                   4 MB
Cache groups:           ( 0 2 1 3 )
--------------------------------------------------------------------------------
********************************************************************************
NUMA Topology
********************************************************************************
NUMA domains:           1
--------------------------------------------------------------------------------
Domain:                 0
Processors:             ( 0 2 1 3 )
Distances:              10
Free memory:            1639.13 MB
Total memory:           5832.04 MB
--------------------------------------------------------------------------------
```

Figure 1

RAM :

— Voir le fichier « .odt » annexe envoyé par Camille.

Le déroulement du projet s'est effectué en plusieurs étapes distinctes :

Analyse du code Cette phase consiste à analyser le programme d'un point de vue d'architecture informatique. Il convient d'étudier les choix mis en œuvres afin d'implémenter le ou les calculs nécessaires.

Protocole expérimental Une fois l'analyse effectuée, nous pouvons en déduire le moyen le plus adapté afin de mesurer les performances de notre implémentation. Nous allons donc mettre en avant les critères théoriques à atteindre dans nos mesures, puis nous exposerons la manière dont nous avons mis ceci en pratique.

Optimisations et mesures Grâce au protocole mis en place, nous pouvons quantifier la performance du programme. De ce fait, nous serons en mesure d'expérimenter différentes techniques d'optimisation sur le programme et d'en calculer l'accélération.

2 Analyse du code

Présentons notre kernel par son prototype, que nous observons sur le Listing 1 Nous voyons qu'il y a 3 variables qui sont manipulées :

— n correspond à la taille de nos tableaux.
— a est un tableau de *float* à deux dimensions dont la taille en fonction de n : $4n^2$ Bytes.
— b est un tableau de *double* à une dimension dont la taille en fonction de n : $8n$ Bytes.

Listing 1 – Prototype du kernel non-optimisé

Nous sommes face à un code de calcul très simple en apparence, illustré dans le Listing 2 : deux boucles imbriquées, un branchement, un calcul mêlant multiplication et exponentiel. Mais plusieurs éléments remarquables qui risquent de poser problème au niveau de la rapidité d'exécution apparaissent alors : les boucles impliquent qu'il faut prêter attention au sens de parcours des tableaux, le branchement nous laisse penser qu'il faudrait essayer de le supprimer, enfin l'exponentiel et la multiplication sont des opérations lourdes.

Listing 2 – Kernel non-optimisé

3 Protocole expérimental

La mise en place d'un protocole expérimental de mesure est une étape nécessaire et cruciale dans tout processus d'optimisation de code. D'une part, le but de ce protocole est de mettre en lumière les points chauds du programme, c'est-à-dire les parties du code qui ralentissent considérablement l'exécution des calculs : ces points chauds seront les cibles de nos optimisations. D'autre part, après chaque tentative d'optimisation, le protocole doit nous permettre de mesurer l'impact de cette dernière, qu'il soit positif ou négatif, et enfin de le quantifier.

3.1 Driver

Le code de notre environnement de mesure est séparé en deux parties : le *driver* et le *kernel*. Le kernel contient la fonction de calcul à proprement dite, sur laquelle nos optimisations se porteront. Le driver est le code qui nous permet d'effectuer nos mesures. Le paragraphe suivant sera consacré à une rapide explication de son fonctionnement, le code étant accessible dans le fichier « *driver.c* ».

Les premières lignes du driver servent à récupérer les options de mesures passées en argument à l'application. Vint ensuite une boucle qui englobe toute l'expérience de mesure, elle correspond à l'exécution des méta-répétitions. Une méta-répétition est une répétition qui comprend l'expérience dans sa globalité. L'utilité d'avoir plusieurs méta-répétitions vient du fait que plusieurs mesures sont nécessaire pour être représentatives, car une mesure isolée pourrait être biaisée. On prend la mesure médiane issues des différentes méta-répétitions. Les premières lignes de la boucle des méta-répétitions correspondent à l'allocation et l'initialisation des tableaux utilisés par le kernel. Il faut faire attention à bien utiliser la mémoire lors de l'initialisation, sinon *Linux* pourrait ne pas vraiment allouer le tableau en mémoire (initialisation paresseuse). Ensuite, nous entrons dans une petite boucle qui effectue le warmup, c'est-à-dire la « mise en chauffe » (terme vague mais expliquant le nom) du processeur. Derrière cette appellation grossière se cache un remplissage de la mémoire cache avec nos tableaux, puisque l'on effectue plusieurs fois la fonction de calcul « dans le vide », sans effectuer de mesure. Cette phase de warmup permet de passer le régime transitoire, ou le temps de calcul s'améliore à chaque itération, pour arriver dans le régime permanent, ou le temps de calcul est stable. Une fois le warmup terminé, on passe à la mesure proprement dite, effectué par l'instruction *RDTSC*. Le choix s'est porté sur cette instruction pour son efficacité : en effet, elle appelle directement une instruction assembleur x86 correspondante, et son imprécision n'est que de quelques dizaines de cycles seulement. Entre nos deux instructions *RDTSC* (start/stop) se trouve une boucle de répétition d'appel du kernel. Cette boucle de répétition est nécessaire afin d'avoir une mesure précise : il se trouve que si on effectuait un seul appel au kernel, il se pourrait que les instructions de mesure (*RDTSC*) et de contrôle prennent autant ou plus de temps que le code de calcul, ce qui biaiserait complètement les résultats. Il faut donc faire plusieurs répétitions afin d'avoir un temps de calcul conséquent par rapport au reste des instructions.

3.2 Théorie

Lors de nos expériences, de nombreux paramètres peuvent être sujets à des variations aléatoires ou à des erreurs de mesure, ainsi un résultat peut être biaisé. Afin d'éviter cela, il est impératif d'utiliser une valeur représentative de nos différentes mesures : une valeur moyenne ou une valeur médiane. La valeur médiane semble être un meilleur candidat contrairement à la moyenne, car cette dernière peut-être fortement modifié par une valeur extrême qui n'as pas lieu d'être. C'est donc la valeur médiane que nous prendrons des résultats de nos mesures successives issues des méta-répétitions.

Pour que chaque membre de l'équipe puisse travailler sur son niveau de mémoire cache, il nous faut trouver la taille des données d'entrée à utiliser. Selon le prototype présenté dans le Listing 1, la taille totale de nos données d'entrées est de $4n^2 + 8n$, avec n la taille entrée en paramètre du programme.

3.2.1 Cache L1

Ci-dessous les paramètres des mesures :

(1) Taille pour tenir dans L1 : $n = 88$. En effet, $(n^2 * 4) + (n * 8) = 31680B$, sachant que la taille du cache est de $32kiB = 2^{15} = 32768B$, et que si l'on prend $n = 90$, on obtient $33120B$, on a bien : $n = 88 < L1 < n = 90$ avec une bonne marge de sécurité.

(2) Nombre de répétitions du warm-up : 1000. Ce nombre est suffisant pour avoir ensuite des mesures stables dans tous nos tests car les caches sont remplis avec nos tableaux, choisi par observation. Il permet donc de passer le régime transitoire.

(3) Nombre de répétitions des mesures : on choisit un nombre qui nous permet d'avoir un temps minimum représentatif par méta-répétition. Ce nombre varie en fonction de la taille de notre tableau. Avoir plus ou moins 1 seconde de mesures permet d'avoir une faible marge d'erreur de mesures des cycles avec un *RDTSC*. Par exemple, pour une taille de 89, on peut choisir 10000.

3.2.2 Cache L2

Pour que les deux tableaux entrent entièrement dans le cache L2, il faut que la formule respecte les contraintes suivantes :

— La taille totale doit être plus grande que la taille du cache L1 (1). Pour plus sécurité il a été décidé que la taille totale devait être au moins trois fois plus grande que celle du L1.

— L2 partage sa mémoire pour stocker à la fois les instructions, les données et ce qui tourne en background, on ne peut donc en utiliser approximativement que 90% (2).

Ces deux contraintes peuvent être transformées sous forme d'inéquation :

— (1) : $3 * TL1 < 4n * n + 8n$,

— (2) : $4n * n + 8n \leq 0,9 * \text{TL2}$
Après la résolution de ces équations on obtient $n = 156$ comme minimum et $n = 242$ comme maximum.

3.2.3 RAM

Voir le fichier « .odt » annexe envoyé par Camille.

3.2.4 Analyse de sensibilité

Une fois que l'on connaît la taille des données a fournir en entrée, il faut effectuer une analyse de sensibilité pour les autres paramètres.

Nombre de méta-répétition des mesures Il nous est donné à 31. C'est le nombre donné dans la consigne, qui est suffisant pour avoir un nombre de mesure significatives.

Le nombre de warmup Il doit se situer entre 1 et 1000. Pour le déterminer, il doit être le seul paramètre que l'ont fait varier. On fait plusieurs exécutions et, avec les valeurs obtenues, on fait une courbe pour voir à partir de quelle valeur cela devient stable. Il faut aussi vérifier que $\frac{\text{médiane}-\text{minimum}}{\text{minimum}}$ est inférieur à 5%.

Le nombre de répétitions On le trouve de la même manière que le nombre de warmup.

3.3 Pratique

Lors de nos premières tentatives pour trouver les paramètres, nous avons remarqué que ce qui prenait le plus de temps dans notre noyau de calcul était l'exponentiel. Afin de pouvoir vérifier si nos paramètres sont corrects, nous avons donc modifié le fichier *kernel.c* pour que ce soit le temps de récupération des données qui soit le plus grand. Cette version n'est utilisé que pour tester la véracité des paramètres trouvés dans la section précédente, et non pas pour évaluer les performances des optimisations ou des compilateurs.

3.3.1 Cache L1

On peut observer une nette différence de performance entre un $n = 88$ et un $n = 90$, qui se traduit par le fait de tenir ou de ne pas tenir en cache *L1*. On assigne le programme de calcul au cœur n°2 de la machine avec *taskset*, sur son numéro de thread physique, dans le but de limiter les changements de contexte et de flush de la mémoire cache. Les tests sont effectués en rescue/failsafe mode, sans interface graphique, permettant d'avoir un minimum de tâches tournant en arrière-plan. De plus, le gouverneur du processeur est sélectionné sur le mode performance et la fréquence est fixé. Toutes les mesures effectuées dans le cache L1 sont automatisées par un script (*report/L1/P{1,2}/bench.sh*). Ce script permet d'aisément exécuter

l'ensemble des tests dans un environnement idéal, ainsi que d'assurer la reproductibilité du protocole expérimental, critère important d'une méthode scientifique. Les compilateurs utilisés sont *GCC v8.3.0*, *Clang v7.0.1*, *ICC v19.0.2.187*, tournants sur un *Debian v10 Buster (testing)* composé du noyau *Linux v4.19.0 x86_ 64*.

3.3.2 Cache L2

Avant de pouvoir executer et mesurer quelque chose il faut s'assurer que la machine n'utilise pas son temps de calcul ou d'accès à la mémoire pour autre chose que notre programme. Pour cela il faut passer en mode root qui n'utilise pas d'interphase graphique et n'est pas connecté au réseau. On connecte la machine au secteur pour qu'elle ne se mette pas en mode economie d'energie. Il faut ensuite ffixer la fréquence à l'aide de *cpupower frequency-set* et enfin lorsque l'on compile le programme il faut aussi fixer le coeur afin d'éviter que le programme s'execute sur plusieurs et qu'il faille transferer des données entre les différents coeurs ce qui ferrait perdre du temps. Pour fixer le coeur on utilise taskset.

Pour vérifier le calcul théorique de la taille des données j'ai utilisé likwid-perftcr afin de voir si les données transitaient bien par le cache L2. Après avoir compilé avec gcc uniquement j'ai exécuté l'exécutable avec likwid et voici les résultats obtenus :

n	Data Volume (GByte)
100	4,24
150	14,06
220	37,9
235	34,4

On observe que ces résultats sont en corrélation avec les résultats théoriques : en dessous de 156 pratiquement aucune donnée ne passe par le cache L2, et quand on se rapproche de 242 une partie des données ne semble plus passer dans L2. Je suppose donc que ces données vont directement dans le cache L3. Au vu de ces informations, j'ai choisi de prendre 220 comme taille de données.

Voici ci-contre le graphique obtenu pour trouver le bon nombre de warmup. On peut observer que le nombre de cycles semble se stabiliser au alentour de 100 warmup. Pour plus de sécurité j'ai choisi 150 pour le nombre de warmup.

J'ai ensuite vérifié avec le calcul de l'exponetiel et on obtient bien le même résultat.

Pour trouver le bon nombre de répétitions j'ai uniquement fait les tests avec l'exponentiel. Comme vous pouvez le voir, on peut remarquer que l'ensemble est stable, les variations sont minimes. J'ai choisit comme nombre de répétitions 1200.

3.3.3 RAM

Voir le fichier « .odt » annexe envoyé par Camille.

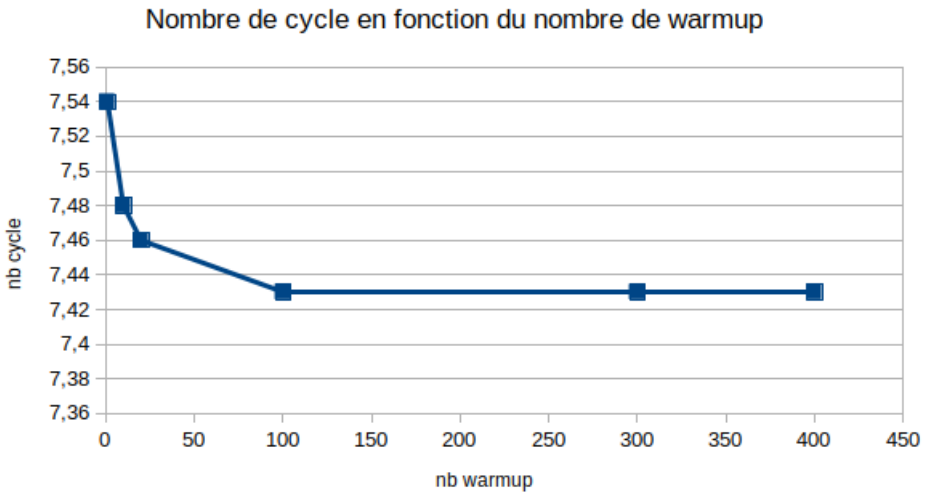

FIGURE 2 – Sans l'exponentiel

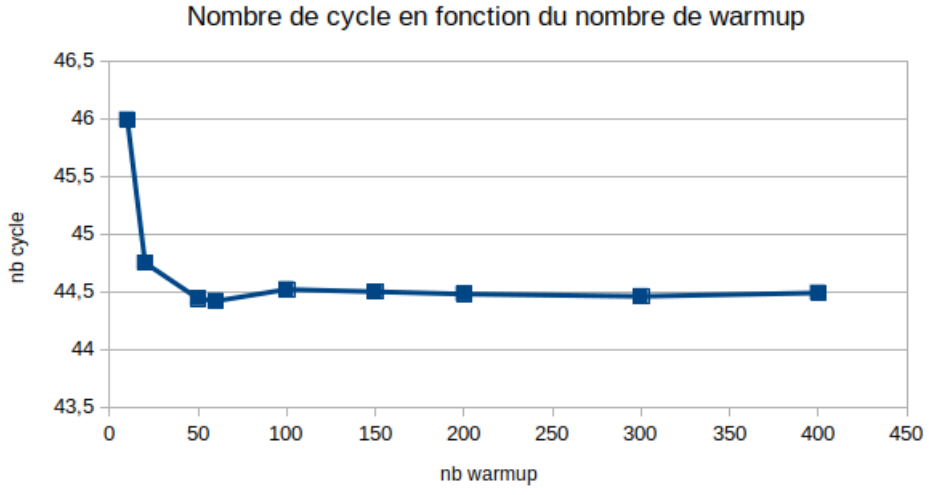

FIGURE 3 – Avec l'exponentiel

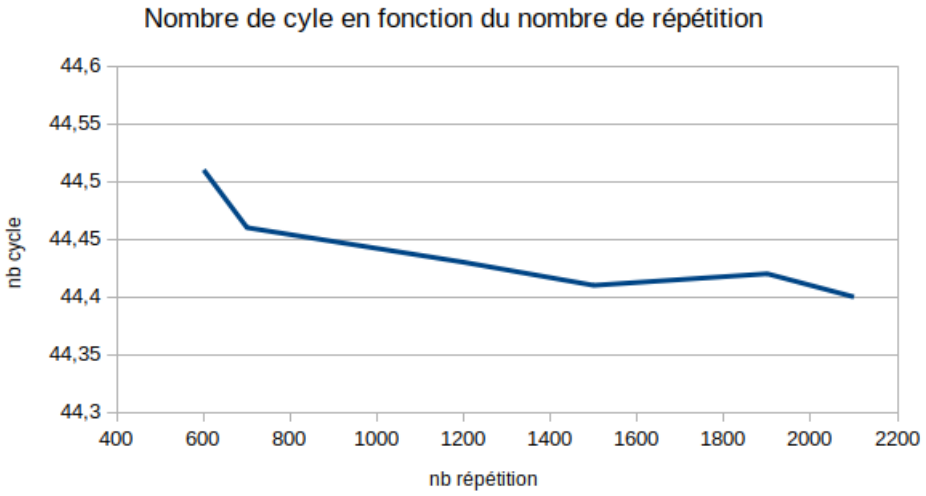
Nombre de cyle en fonction du nombre de répétition
44,6
44,55
44,5
44,45
44,4
44,35
44,3
nb cycle
400
600
800
1000
1200
1400
1600
1800
2000
2200
nb répétition

FIGURE 4

4 Optimisations et mesures

Dans cette section, nous présentons les résultats des mesures des différentes tentatives d'optimisation du code. La phase 1 correspond, pour résumer, à identifier les points chauds et tester différentes configurations de compilation. La phase 2 correspond, notamment, à une optimisation active du code en y apportant des modifications.

4.1 Phase 1

4.1.1 Cache L1

Pour cette première phase de test sur un jeu de donnée dans le niveau de cache L1, nous avons testé 3 compilateurs (« gcc », « icc », « clang ») avec différents jeux de flags de compilation. Nous précisons que l'intégralité de nos résultats sont disponibles sous formes brut dans les fichiers/répertoires suivants : « compil.txt », « likwid_{ref,opt} », « maqao_{ref,opt} ».

En plus des flags qui sont donnés dans la consigne, nous avons également testé le flag « -Ofast » qui permet d'activer des optimisations mathématiques qui ne respecte pas les standards en vigueur. Un programme qui ne requiert pas une stabilité numérique très précise obtiendra des gains considérable avec cette option, cependant, cela peut être dangereux de l'activer sans possibilité de vérifier les résultats des calculs du kernel. Nous avons ici pris le pari de l'activer.

Nous avons aussi testés d'autres options ciblées : fonctions inline, optimisations sur les boucles, sur les fonctions mathématiques ou encore sur les branchements. La liste ci-dessous présente les flags qui n'auront pas apporté de gain, ou pire, auront provoqué une accélération négative par rapport à « -Ofast -march=native » : « -faggressive-loop-optimizations », « -fbranch-probabilities », « -fdelayed-branch », « -fexpensive-optimizations », « -finline-functions », « -floop-block », « -floop-interchange », « -floop-unroll-and-jam », « -funsafe-math-optimizations ». Cependant, le flag « -funroll-all-loops », permettant de forcer l'unrolling des boucles, nous aura octroyé un léger gain systématique.

Dans la Table 1 est présenté la liste des résultats sur les flags obligatoires et les flags apportant un gain (les flags inutiles ou ralentissant ne sont pas inclus pour des soucis de visibilité). Nous pouvons ainsi voir que c'est « gcc », couplé à certaines options, qui est le plus rapide face à « clang » et « icc ». Nous notons tout de même l'efficacité redoutable de la génération de code spécialement pour l'architecture hôte (« -march=native »), permettant d'utiliser les instructions x86 les plus récentes, et des optimisations mathématiques agressives (« -Ofast »).

Nous avons ensuite utiliser les outils *MAQAO* et *LIKWID* pour expliquer les différences de performances entre deux versions du code. Après nos tests avec notre script permettant de détecter les flags permettant d'avoir le meilleur speed-up, nous allons étudier les différences de performances entre la version de référence « gcc -O2 »

Compiler	Flags	Time (s)
gcc	-O2	22.90
gcc	-O3	22.58
gcc	-Os	47.99
gcc	-O3 -march=native	22.77
gcc	-Ofast	9.59
gcc	-Ofast -march=native	4.64
gcc	-Ofast -march=native -funroll-all-loops	4.42
clang	-O0	30.38
clang	-O2	23.18
clang	-O3	26.04
clang	-Os	23.11
clang	-O3 -march=native	26.21
clang	-Ofast	18.18
clang	-Ofast -march=native	25.97
icc	-O0	23.05
icc	-O2	16.25
icc	-O3	16.27
icc	-Os	15.96
icc	-O3 -xHost	17.08
icc	-Ofast	16.25
icc	-Ofast -xHost	16.41
icc	-Ofast -xHost -funroll-loops -unroll-aggressive	16.39

TABLE 1 – Benchmarks des compilateurs et flags

et la version la plus rapide, « gcc -Ofast -march=native -funroll-all-loops ».

Procédons tout d'abord à une analyse rapide avec *LIKWID*, les résultats étant présentés dans la Figure 5. Nous pouvons expliquer la différence de performance par les métriques suivantes concernant la mémoire : on observe que la version optimisé à fait un nombre significativement moins important que la version de référence d'éviction de données du cache L1 (2.051.211 vs. 16.140.154), ainsi qu'un ratio de miss bien plus faible dans le cache L2 (0.0001 vs. 0.0259).

Enfin, passons à l'étude avec MAQAO. Sur le page « Global » présenté par la Figure 6, nous pouvons déjà avoir une très bonne idée des différences entre les deux binaires, justifiant d'une telle accélération (acc = $\frac{212}{41} = 5.2$). Premièrement, nous observons que sur le binaire optimisé, nous passons deux fois plus de temps dans la boucle que dans la version de référence : cela signifie que les fonctions mathématiques (multiplication, mais surtout l'exponentiel) ont été considérablement optimisées. Ensuite, nous voyons que la version de référence présente deux chemins (Flow Complexity) dans la boucle, tandis que la version optimisée ne présente qu'un chemin d'exécution possible. Nous notons aussi que l'efficacité d'accès aux données (Array Access Efficiency) a été augmenté de 20% dans la version optimisée, sûrement par modifications des boucles imbriquées. Enfin, nous pouvons imaginer une tentative de vectorisation de la part du compilateur pour la version optimisée.

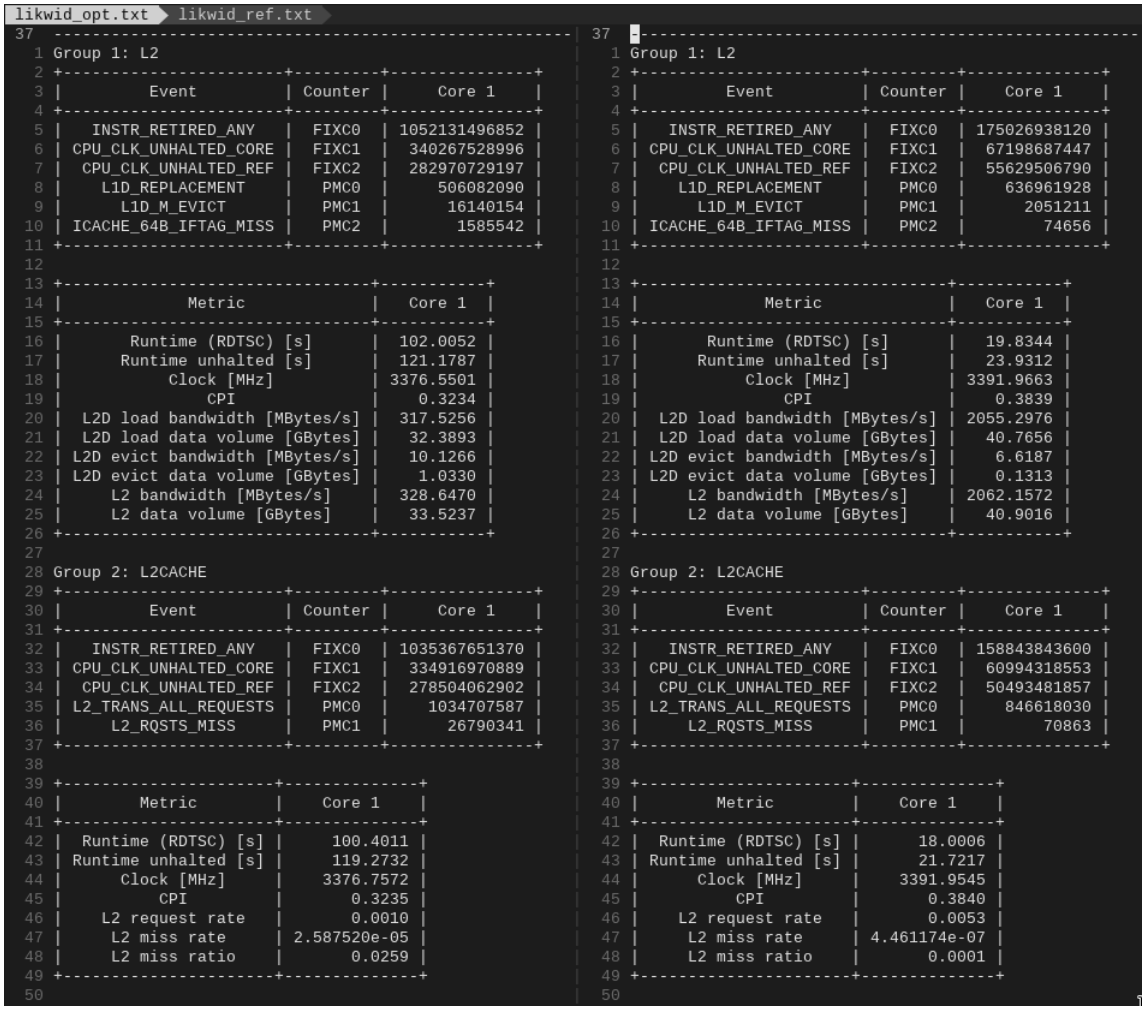

FIGURE 5 – A gauche, la version de référence. A droite, la version avec les flags d'optimisation.

Pour finir avec l'analyse de *MAQAO*, sur la Figure 7, nous pouvons observer ce qu'à concrètement fait le compilateur. La fonction exponentielle, qui prenait 14% du temps, à été remplacé par une version optimisée « fini », ne prenant plus que 1.46% du temps. Nous pouvons voir que le linkage de la bibliothèque mathématique (*libm*) a été remplacé par sa version vectorisée (*libmvec*). Enfin, nous observons que notre unique boucle à bien été déroulée car nous trouvons l'ajout d'une *tail loop*.

4.1.2 Cache L2

On remarque avec ces résultats que icc rend l'exécution plus rapide que gcc, néanmoins, les différentes options d'optimisation n'ont pas un impact considérable contrairement à gcc qui entre O2 et O3 gagne quelques secondes.

À l'aide de LIKWID, on peut observer que le volume de data est différent entre l'exécution avec icc et gcc, il est d'environ 37 GBytes avec gcc et 7 GBytes avec icc. Le miss rate est équivalent entre les deux compilateur.

Numéro	Commande	Résultat (médiane)
1	gcc -O2	39,93
2	gcc -O3	37,62
3	gcc -O3 -march=native	37,79
4	icc -O2	17,79
5	icc -O3	17,77
6	icc -O3 -xHost	17,74

4.1.3 RAM

Voir le fichier « .odt » annexe envoyé par Camille.

4.2 Phase 2

TODO

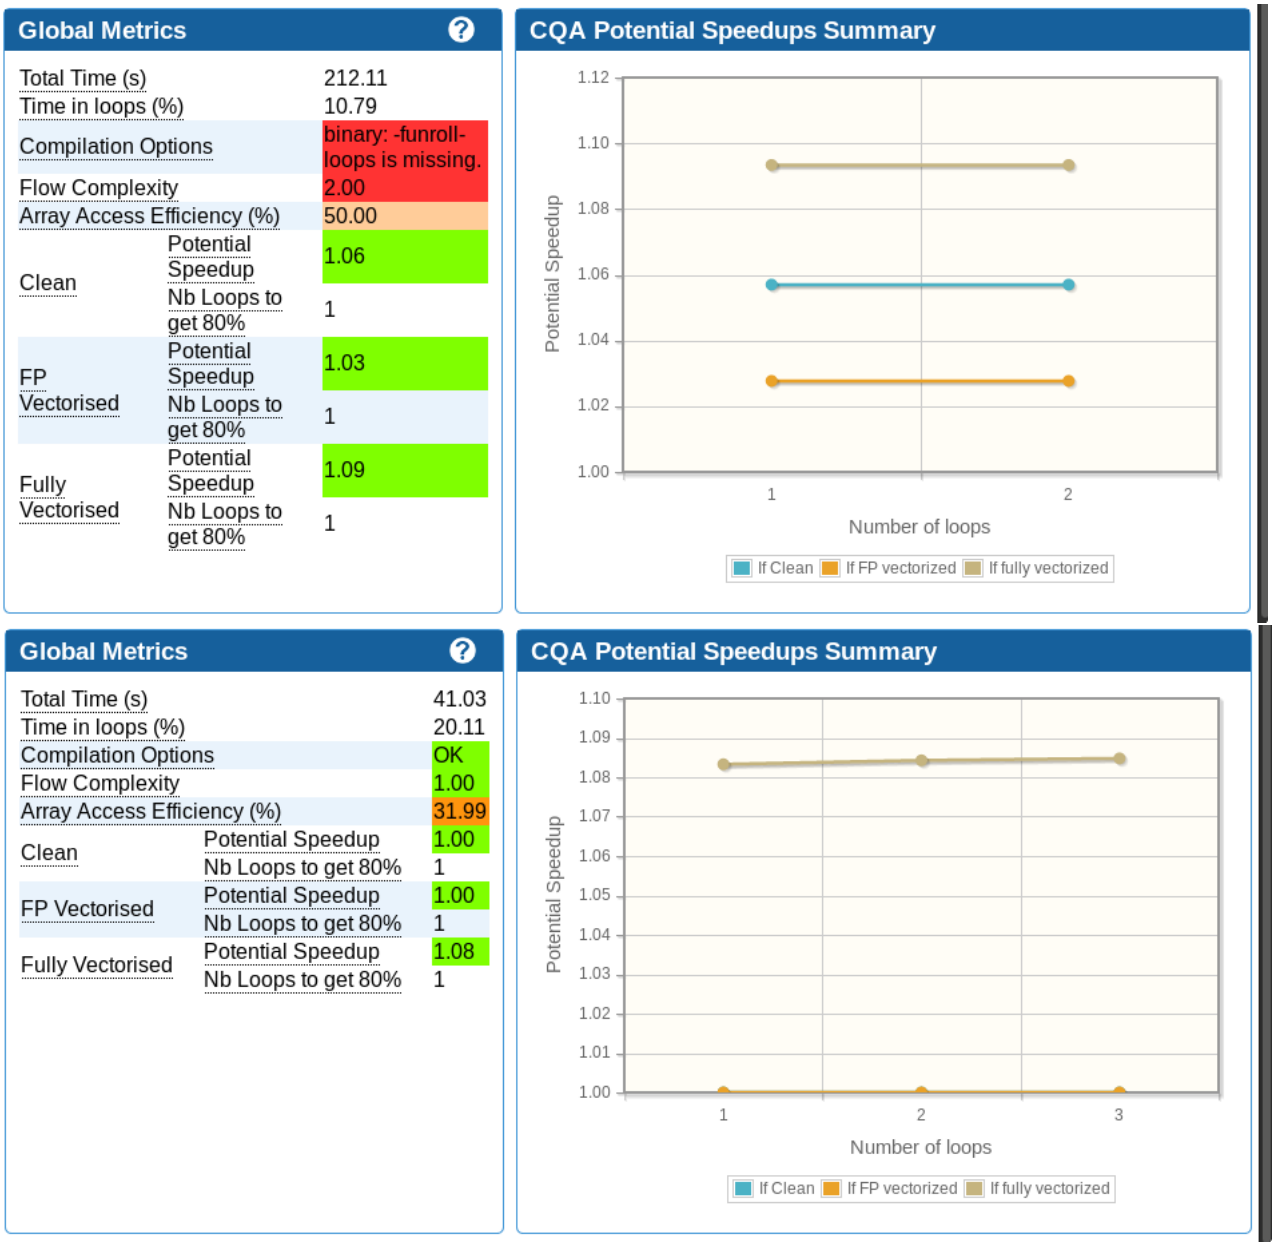

FIGURE 6 – Au-dessus, la version de référence. En dessous, la version avec les flags d'optimisation.

Functions and Loops

▶ **Filters**

Name	Module	Coverage (%)	Time (s)	Nb Threads	Deviation (coverage)
○ f64xsubf128	libm-2.28.so	63.65	135.01	1	0.00
○ exp	libm-2.28.so	14.61	30.99	1	0.00
▼ baseline	baseline	10.88	23.07	1	0.00
▼ Loop 7 - kernel.c:13-19 - baseline		10.79	22.89		
○ Loop 6 - kernel.c:16-19 - baseline		10.79	22.89		

Functions and Loops

▶ **Filters**

Name	Module	Coverage (%)	Time (s)	Nb Threads	Deviation (coverage)
○ _ZGVeN16vvv_sincosf	libmvec-2.28.so	74.29	30.48	1	0.00
▼ baseline	baseline	24.08	9.88	1	0.00
▼ Loop 8 - - baseline		20.06	8.23		
▼ Loop 6 - - baseline		19.84	8.14		
○ Loop 7 - - baseline		19.84	8.14		
○ Loop 9 - - baseline		0.22	0.09		
○ _ZGVdN4v___exp_finite	baseline	1.46	0.6	1	0.00

FIGURE 7 – Au-dessus, la version de référence. En dessous, la version avec les flags d'optimisation.

5 Conclusion

TODO

Acronymes